

FIAP – FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA
Pós-Tech em Inteligência Artificial para Devs

Alex Nascimento Gonçalves

Camila Utz

Eric Tamashiro Kurachi

Lucas Henrique Barbosa Silva

Raphael Gomes

TECH CHALLENGE – FASE 2
OTIMIZAÇÃO DE MODELOS DE DIAGNÓSTICO POR
ALGORITMOS GENÉTICOS E INTEGRAÇÃO COM LARGE
LANGUAGE MODELS

1 INTRODUÇÃO

O diagnóstico precoce de doenças é um dos principais fatores para apoiar decisões clínicas e aumentar as possibilidades de tratamento. Nesse contexto, técnicas de Inteligência Artificial e Machine Learning podem ser utilizadas como ferramentas de apoio à análise de dados médicos, identificando padrões que auxiliem profissionais da área da saúde.

Neste projeto foi utilizado o Wisconsin Breast Cancer Dataset, composto por dados relacionados ao diagnóstico de câncer de mama. O problema foi tratado como uma tarefa de classificação supervisionada binária, na qual os registros podem ser classificados como malignos ou benignos.

Como modelo preditivo, foi utilizado o algoritmo Random Forest, inicialmente treinado com uma configuração de hiperparâmetros definida como baseline. Posteriormente, foi implementado um Algoritmo Genético (AG) para realizar a busca por combinações mais adequadas de hiperparâmetros para o modelo.

A otimização foi realizada utilizando princípios inspirados no processo evolutivo, em que diferentes combinações de hiperparâmetros são representadas como indivíduos de uma população. Esses indivíduos são avaliados por meio de uma função de fitness e, ao longo das gerações, são submetidos a operações de seleção, cruzamento e mutação.

Além da otimização do modelo, o projeto incorporou uma camada de Processamento de Linguagem Natural utilizando uma Large Language Model (LLM). Foi utilizada a LLM Claude, da Anthropic, para transformar resultados numéricos e estatísticos produzidos pelo modelo em explicações em linguagem natural, com o objetivo de melhorar a interpretabilidade dos resultados.

Também foram implementados mecanismos de logging e monitoramento das chamadas realizadas à LLM, além de uma abordagem para avaliação automática da qualidade das explicações geradas. Essa avaliação combinou checagens heurísticas e o conceito de LLM-as-judge, no qual uma segunda chamada à LLM é utilizada para avaliar critérios relacionados à clareza, fidelidade aos dados, utilidade e segurança da resposta.

Dessa forma, a solução desenvolvida integra três componentes principais: um modelo de Machine Learning para classificação, um Algoritmo Genético para otimização de

hiperparâmetros e uma LLM para interpretação dos resultados e geração de insights em linguagem natural.

2 ARQUITETURA GERAL DA SOLUÇÃO

A solução foi organizada como um pipeline composto por diferentes etapas.

Inicialmente, os dados do Wisconsin Breast Cancer Dataset são carregados e preparados para utilização pelo modelo de Machine Learning. Após a preparação dos dados, um modelo Random Forest é treinado utilizando uma configuração inicial de hiperparâmetros, estabelecendo o baseline do projeto.

Em seguida, o Algoritmo Genético realiza a busca por melhores combinações de hiperparâmetros. Cada indivíduo representa uma configuração do Random Forest, e sua qualidade é avaliada utilizando o F1-score obtido no conjunto de validação.


Após a execução dos experimentos, o melhor indivíduo encontrado é utilizado para criar o modelo otimizado. Esse modelo é treinado utilizando os conjuntos de treino e validação combinados e posteriormente avaliado no conjunto de teste.


Os resultados produzidos pelo modelo otimizado são então disponibilizados para a camada de interpretação baseada em LLM. A LLM Claude recebe informações estruturadas sobre os resultados e gera explicações em linguagem natural, além de relatórios consolidados.

Por fim, as respostas produzidas pela LLM passam por mecanismos de avaliação de qualidade.

O fluxo geral da solução pode ser representado da seguinte forma:

Figura 1 – Fluxo geral do pipeline da solução





Fonte: elaborado pela autora (2026).

3 DADOS UTILIZADOS

O projeto utilizou o Wisconsin Breast Cancer Dataset, disponibilizado no Kaggle.

O conjunto de dados contém informações relacionadas a características extraídas de exames de tumores de mama. O atributo utilizado como variável-alvo foi diagnosis, que representa duas classes:

- M: diagnóstico maligno;
- B: diagnóstico benigno.

O problema foi tratado como uma tarefa de classificação supervisionada binária.

O dataset contém diversas características numéricas relacionadas às propriedades dos tumores. Entre elas estão medidas relacionadas a raio, textura, perímetro, área, suavidade, compactação, concavidade, simetria e dimensão fractal.

Durante a preparação dos dados, foram removidas colunas que não contribuíam para a tarefa de classificação, como identificadores e colunas sem informações relevantes para o treinamento do modelo.

Após a preparação, os dados foram separados em conjuntos destinados ao treinamento, validação e teste.

A utilização de conjuntos separados teve como objetivo evitar que o conjunto de teste fosse utilizado durante a busca dos hiperparâmetros. Dessa forma, o Algoritmo Genético utiliza o desempenho no conjunto de validação para avaliar os indivíduos, enquanto o conjunto de teste permanece reservado para a avaliação final do modelo.

4 MODELO DE MACHINE LEARNING

4.1 Escolha do Random Forest

O algoritmo escolhido para o problema de classificação foi o Random Forest Classifier.

O Random Forest é um modelo baseado na construção de múltiplas árvores de decisão. Durante o treinamento, diferentes árvores são construídas e suas previsões são combinadas para produzir a classificação final.

A escolha do Random Forest permitiu trabalhar com diferentes hiperparâmetros que influenciam diretamente o comportamento e a complexidade do modelo.

Entre os hiperparâmetros selecionados para otimização estão:

- `n_estimators`;
- `max_depth`;
- `min_samples_split`;
- `max_features`.

Esses parâmetros foram posteriormente utilizados como genes dos indivíduos do Algoritmo Genético.

5 MODELO ORIGINAL

Antes da aplicação do Algoritmo Genético, foi treinado um modelo Random Forest utilizando uma configuração inicial de hiperparâmetros.

Esse modelo foi utilizado como base para permitir a comparação entre o desempenho inicial e o desempenho obtido após a otimização.

A avaliação final do modelo baseline no conjunto de teste apresentou os seguintes resultados:

Tabela 1 – Resultados do modelo original (baseline) no conjunto de teste

Métrica	Modelo original
Accuracy	0,976744
Recall	0,937500
F1-score	0,967742

Fonte: elaborado pela autora (2026).

Os resultados indicam que o modelo baseline já apresentava um desempenho elevado para o conjunto de dados utilizado. Dessa forma, o objetivo do Algoritmo Genético foi verificar se seria possível encontrar combinações de hiperparâmetros capazes de melhorar ainda mais o desempenho do modelo.

6 OTIMIZAÇÃO DE HIPERPARÂMETROS UTILIZANDO ALGORITMOS GENÉTICOS

6.1 Representação dos indivíduos

No Algoritmo Genético implementado, cada indivíduo representa uma configuração possível dos hiperparâmetros do Random Forest.

A estrutura de um indivíduo é composta por quatro genes:

[n_estimators, max_depth, min_samples_split, max_features]

Cada combinação representa uma configuração específica do modelo.

Por exemplo, o melhor indivíduo encontrado durante os experimentos foi:

[120, 10, 6, 'sqrt']

Essa representação corresponde a:

- n_estimators = 120;
- max_depth = 10;
- min_samples_split = 6;
- max_features = 'sqrt'.

A utilização dessa estrutura permitiu que cada configuração fosse manipulada pelos operadores genéticos.

6.2 Inicialização da população

A população inicial é formada por diferentes indivíduos gerados com valores possíveis para os hiperparâmetros definidos.

Cada indivíduo representa uma solução candidata para o problema de otimização.

Dessa forma, uma população pode ser representada conceitualmente como:

Indivíduo 1 $\rightarrow$ [100, 8, 4, 'sqrt']

Indivíduo 2 $\rightarrow$ [120, 10, 6, 'sqrt']

Indivíduo 3 $\rightarrow$ [150, 12, 2, 'log2']

...

A diversidade da população permite que o Algoritmo Genético explore diferentes regiões do espaço de busca.

6.3 Função de fitness

A função de fitness foi baseada no F1-score obtido pelo modelo no conjunto de validação.

O F1-score foi escolhido como métrica de fitness por combinar informações relacionadas à precisão e ao recall.

Para cada indivíduo, o processo de avaliação ocorre da seguinte forma:

1. os genes do indivíduo são utilizados para configurar um Random Forest;
2. o modelo é treinado utilizando o conjunto de treinamento;
3. o modelo realiza previsões sobre o conjunto de validação;
4. o F1-score é calculado;
5. o valor obtido é utilizado como fitness do indivíduo.

Assim, indivíduos que produzem modelos com maior F1-score recebem uma avaliação melhor e possuem maior probabilidade de contribuir para as gerações seguintes.

6.4 Seleção

A etapa de seleção tem como objetivo identificar os indivíduos mais adequados para participar da reprodução.

O princípio utilizado é que indivíduos com melhor fitness devem possuir maior possibilidade de transmitir suas características para as próximas gerações.

Dessa forma, configurações de hiperparâmetros que apresentam melhor desempenho no conjunto de validação são favorecidas durante o processo evolutivo.

6.5 Cruzamento

O operador de cruzamento, também chamado de crossover, combina genes de dois indivíduos selecionados.

O objetivo é gerar novos indivíduos que possivelmente combinem características positivas encontradas em diferentes soluções.

Por exemplo:

Pai 1: [120, 10, 4, 'sqrt']

Pai 2: [150, 8, 6, 'log2']

Um possível descendente pode combinar genes de ambos:

Filho: [120, 8, 6, 'sqrt']

Esse processo permite explorar novas combinações de hiperparâmetros sem depender exclusivamente da geração aleatória de soluções.

6.6 Mutação

A mutação é responsável por introduzir alterações nos genes dos indivíduos.

Durante esse processo, determinados genes podem ser modificados aleatoriamente dentro dos valores permitidos.

A mutação é importante para manter a diversidade genética da população e evitar que o algoritmo permaneça restrito a uma região específica do espaço de busca.

Por exemplo:

Indivíduo original:

[120, 10, 6, 'sqrt']

Após mutação:

[120, 12, 6, 'sqrt']

A taxa de mutação foi uma das configurações avaliadas nos diferentes experimentos realizados.

7 EXPERIMENTOS REALIZADOS

Foram realizados três experimentos utilizando diferentes configurações do Algoritmo Genético.

Os experimentos variaram parâmetros relacionados ao funcionamento do próprio algoritmo, como:

- tamanho da população;
- quantidade de gerações;
- taxa de mutação.

A realização de diferentes experimentos permitiu observar como essas configurações influenciam a evolução do fitness ao longo das gerações.

Para cada experimento, foram armazenados:

- o melhor indivíduo encontrado;
- o melhor fitness obtido;
- a evolução do melhor fitness ao longo das gerações;
- a evolução do fitness médio da população.

Os gráficos gerados permitem observar o comportamento do processo evolutivo.

A comparação entre o melhor fitness e o fitness médio é importante para avaliar se a população apresentou evolução durante as gerações e para observar o comportamento da convergência.

O melhor indivíduo entre todos os experimentos foi:

[120, 10, 6, 'sqrt']

O F1-score de validação associado a esse indivíduo foi:

0,9508

Esse conjunto de hiperparâmetros foi utilizado para a construção do modelo final.

8 MODELO OTIMIZADO

Após a conclusão dos experimentos, o melhor conjunto de hiperparâmetros encontrado pelo Algoritmo Genético foi utilizado para construir o modelo Random Forest otimizado.

A configuração encontrada foi:

Quadro 1 – Configuração de hiperparâmetros do modelo otimizado

Hiperparâmetro	Valor
n_estimators	120
max_depth	10
min_samples_split	6
max_features	sqrt

Fonte: elaborado pela autora (2026).

Após a seleção da melhor configuração, os conjuntos de treino e validação foram combinados para realizar o treinamento do modelo final.

O conjunto de teste permaneceu separado e foi utilizado apenas para a avaliação final.

O modelo otimizado apresentou os seguintes resultados:

Tabela 2 – Resultados do modelo otimizado no conjunto de teste

Métrica	Modelo otimizado
Accuracy	0,988372
Recall	0,968750
F1-score	0,984127

Fonte: elaborado pela autora (2026).

9 COMPARAÇÃO ENTRE O MODELO ORIGINAL E O MODELO OTIMIZADO

A comparação final entre os modelos foi realizada utilizando o mesmo conjunto de teste.

Tabela 3 – Comparação entre o modelo original e o modelo otimizado

Modelo	Accuracy	Recall	F1-score
Original	0,976744	0,937500	0,967742
Otimizado	0,988372	0,968750	0,984127

Fonte: elaborado pela autora (2026).

Os resultados demonstram melhora nas três métricas avaliadas.

A accuracy aumentou de aproximadamente 97,67% para 98,84%.

O recall aumentou de 93,75% para 96,88%.

O F1-score aumentou de aproximadamente 96,77% para 98,41%.

O aumento do recall é particularmente relevante dentro do contexto do problema, pois essa métrica está relacionada à capacidade do modelo de identificar corretamente exemplos pertencentes à classe positiva utilizada na avaliação.

A melhoria simultânea do recall e do F1-score indica que a configuração encontrada pelo Algoritmo Genético apresentou melhor desempenho geral em comparação com o modelo baseline.

Dessa forma, os resultados obtidos demonstram que a aplicação do Algoritmo Genético foi capaz de encontrar uma combinação de hiperparâmetros que apresentou desempenho superior ao modelo original.

10 INTEGRAÇÃO COM LARGE LANGUAGE MODEL

10.1 Objetivo da integração

A camada de LLM foi incorporada ao projeto com o objetivo de melhorar a interpretabilidade dos resultados produzidos pelo modelo de Machine Learning.

Modelos de classificação produzem resultados predominantemente numéricos, como:

- classe prevista;
- probabilidades;
- métricas de desempenho.

Embora essas informações sejam importantes para avaliação técnica, sua interpretação pode ser facilitada quando são apresentadas em linguagem natural.

Para essa finalidade, foi integrada a LLM Claude, da Anthropic.

A LLM recebe informações estruturadas relacionadas ao resultado produzido pelo modelo e transforma essas informações em explicações textuais.

10.2 Explicações por caso

A LLM foi utilizada para gerar explicações individuais sobre os resultados produzidos pelo modelo.

Os dados fornecidos para a LLM incluem informações estruturadas relacionadas ao caso e à probabilidade produzida pelo modelo.

A resposta solicitada é estruturada para apresentar informações como:

- resumo;
- interpretação dos números;
- pontos de atenção;
- sugestão de próximos passos;
- limitações.

Essa estrutura foi definida como parte da estratégia de prompt engineering utilizada no projeto.

A utilização de uma estrutura padronizada permite que as respostas apresentem maior consistência e facilita sua posterior avaliação.

10.3 Prompt engineering

Foram utilizadas instruções explícitas para orientar o comportamento da LLM.

O objetivo do prompt engineering foi garantir que a resposta:

- fosse baseada nos dados fornecidos;
- apresentasse uma interpretação clara;
- não inventasse informações que não estivessem disponíveis no payload;
- não apresentasse o resultado como um diagnóstico definitivo;
- destacasse limitações;

- sugerisse próximos passos de maneira contextualizada.

Essa abordagem é especialmente importante no contexto médico, pois uma resposta gerada por uma LLM não deve ser interpretada como substituta da avaliação de um profissional.

A LLM foi utilizada como uma camada de interpretação e apresentação das informações produzidas pelo modelo, e não como mecanismo independente de diagnóstico.

11 GERAÇÃO DE RELATÓRIO EXECUTIVO

Além das explicações individuais, a LLM também foi utilizada para gerar uma visão consolidada dos resultados.

O objetivo do relatório executivo é transformar informações técnicas e métricas numéricas em uma apresentação textual mais adequada para análise.

Essa camada pode consolidar informações relacionadas ao desempenho do modelo e destacar aspectos relevantes identificados durante o processamento.

Dessa forma, a integração com a LLM amplia a capacidade de apresentação da solução, permitindo que informações originalmente técnicas sejam disponibilizadas de maneira mais compreensível.

12 LOGGING ESTRUTURADO E MONITORAMENTO

Foi implementado um mecanismo de logging estruturado para registrar informações relacionadas à execução do pipeline.

Os logs são utilizados para acompanhar chamadas realizadas à LLM e registrar informações relacionadas ao funcionamento da aplicação.

A implementação também permite salvar os registros em arquivo, identificado no projeto como:

`pipeline_metrics.log`

O mecanismo de monitoramento foi integrado às chamadas realizadas ao Claude por meio de um decorator.

Esse recurso permite registrar informações relacionadas à execução das chamadas, contribuindo para a observabilidade do pipeline.

A presença de logging estruturado facilita a identificação de problemas, o acompanhamento das chamadas realizadas e a análise do comportamento do sistema.

13 AVALIAÇÃO DA QUALIDADE DAS INTERPRETAÇÕES GERADAS PELA LLM

A avaliação das respostas geradas pela LLM foi realizada utilizando duas abordagens complementares:

1. checagens heurísticas;
2. LLM-as-judge.

13.1 Checagens heurísticas

As checagens heurísticas foram utilizadas para identificar automaticamente características básicas das respostas.

Entre os critérios avaliados estão:

- presença da probabilidade informada no payload;
- ausência de afirmações absolutas proibidas;
- presença das seções esperadas;
- tamanho adequado da resposta.

Entre as expressões consideradas inadequadas estão afirmações absolutas como:

- “com certeza é”;
- “definitivamente é câncer”;
- “diagnóstico confirmado”;
- “não há dúvida”;
- “100% maligno”;
- “100% benigno”.

Essa abordagem busca identificar respostas que possam apresentar um nível inadequado de certeza.

Também foi definida uma estrutura mínima esperada para as explicações:

- Resumo;
- Interpretação dos números;
- Pontos de atenção;
- Sugestão de próximos passos;
- Limitações.

As checagens heurísticas representam uma primeira camada de validação automatizada.

13.2 Avaliação utilizando LLM-as-judge

A segunda abordagem utiliza uma LLM para avaliar explicações geradas anteriormente.

Nesse processo, a LLM avaliadora recebe:

- os dados originais utilizados como referência;
- a explicação gerada;
- critérios de avaliação.

Os critérios utilizados são:

13.2.1 Clareza

Avalia se a explicação é compreensível para um profissional da área da saúde que não seja especialista em Machine Learning.

13.2.2 Fidelidade aos dados

Avalia se a resposta utiliza apenas as informações presentes nos dados fornecidos, sem inventar resultados ou achados.

13.2.3 Utilidade clínica

Avalia se a resposta apresenta informações ou próximos passos que possam ser considerados úteis no contexto apresentado.

13.2.4 Segurança

Avalia se a explicação evita apresentar o resultado como um diagnóstico definitivo.

Cada critério recebe uma nota de 1 a 5.

Além das notas, a LLM avaliadora também fornece uma justificativa para a avaliação.

Essa abordagem permite complementar as regras heurísticas com uma análise mais contextualizada da qualidade das respostas.

14 LIMITAÇÕES DA AVALIAÇÃO DA LLM

Apesar dos mecanismos implementados, a avaliação automática apresenta limitações.

A amostra utilizada para demonstração possui três casos. Dessa forma, os resultados da avaliação não devem ser interpretados como uma validação abrangente da qualidade do sistema.

Em um ambiente de produção, seria necessário avaliar uma quantidade significativamente maior de casos e realizar monitoramento contínuo das respostas.

Outra limitação está relacionada ao uso de LLM-as-judge. Modelos de linguagem podem apresentar vieses durante a avaliação de respostas geradas por outros modelos.

Por esse motivo, uma abordagem mais robusta poderia incluir revisão humana periódica, especialmente por profissionais especializados na área médica.

As checagens heurísticas também possuem limitações, pois utilizam regras simples para identificar determinados padrões. Essas verificações podem identificar falhas mais evidentes, mas não substituem uma auditoria completa do conteúdo.

Por fim, a solução desenvolvida deve ser compreendida como um **protótipo educacional**. Os resultados produzidos pelo modelo e as interpretações geradas pela LLM não devem ser utilizados para decisões clínicas reais sem validação técnica, clínica e regulatória apropriada.

15 CONCLUSÃO

Foram realizados três experimentos utilizando diferentes configurações do Algoritmo Genético. Durante o processo evolutivo, os indivíduos foram avaliados com base no F1-score obtido no conjunto de validação.

A melhor configuração encontrada foi:

[120, 10, 6, 'sqrt']

Utilizando essa configuração, o modelo otimizado apresentou desempenho superior ao modelo original em todas as métricas avaliadas.

A accuracy aumentou de 0,976744 para 0,988372. O recall aumentou de 0,937500 para 0,968750. O F1-score aumentou de 0,967742 para 0,984127.

Esses resultados demonstram que o Algoritmo Genético foi capaz de encontrar uma combinação de hiperparâmetros que apresentou melhor desempenho no conjunto de teste em comparação com o modelo baseline.

Além da otimização, a integração com a LLM Claude permitiu adicionar uma camada de interpretação dos resultados. As informações numéricas produzidas pelo modelo puderam ser transformadas em explicações em linguagem natural e relatórios consolidados.

A utilização de prompt engineering buscou orientar a geração das respostas, especialmente em relação à fidelidade aos dados, à clareza das explicações e à necessidade de evitar conclusões absolutas.

Também foi implementada uma abordagem para avaliação da qualidade das respostas geradas pela LLM. Essa avaliação combinou checagens heurísticas e LLM-as-judge, permitindo analisar aspectos relacionados à clareza, fidelidade aos dados, utilidade e segurança.

Por fim, o projeto demonstra como diferentes técnicas podem ser combinadas em uma solução de Inteligência Artificial. O Algoritmo Genético contribui para a otimização do modelo preditivo, enquanto a LLM contribui para a interpretação e apresentação dos resultados.

Embora a solução apresente resultados positivos no contexto do dataset utilizado, ela deve ser compreendida como um protótipo educacional. A utilização de sistemas semelhantes em ambientes clínicos reais exigiria validação adicional, avaliação especializada e conformidade com requisitos técnicos, éticos e regulatórios.